SPRAWOZDANIE

Zajęcia: Analiza Procesów Uczenia Prowadzący: prof. dr hab. Vasyl Martsenyuk

Laboratorium 6

Data 12.05.2023r.

Temat: "Ucznie głębokie w R. Klasyfikator obrazów za pomocą Keras"

Wariant 5

Jarosław Waliczek Informatyka II stopień, stacjonarne 1 semestr

1. Polecenie:

Zadanie dotyczy konstruowania sieci głębokiej w celu klasyfikacji obrazów pobranych ze zbioru danych. Warianty zadania są określone zbiorem danych obrazów, który może być pobrany na stronie https://keras.io/api/datasets/

5. CIFAR-10

2. Wprowadzane dane:

Dane są pobrane ze strony https://keras.io/api/datasets/

3. Wykorzystane komendy:

Konfiguracja bibliotek i ładowanie danych:

```
1 setwd("C:/Users/jaro9/OneDrive/Desktop/apu/zad6")
 3 install.packages("keras")
 4 library("keras")
 5 install.packages("tensorflow")
 6 library("tensorflow")
 7 tensorflow::install_tensorflow()
   library(reticulate)
9 library(keras)
10 virtualenv_create("myenv")
11 install_keras(method="virtualenv", envname="myenv")
12 #load data cifar 10
13 cifar <- dataset_cifar10()</pre>
14
15 x_train <- cifar$train$x
16 x_test <- cifar$test$x
17 y_train <- cifar$train$y</pre>
18 y_test <- cifar$test$y
```


```
20 #----- wersja liniowa
21
22 #set up data
23 #change matrix shape
24 x_train <- array_reshape(x_train, c(nrow(x_train), 3072))</pre>
25 #normalize
26 x_train <- x_train / 255
27
28 x_test <- array_reshape(x_test, c(nrow(x_test), 3072))</pre>
29 x_test <- x_test / 255
30
31
   #set classes
32 y_train <- to_categorical(y_train, num_classes = 10)</pre>
33 y_test <- to_categorical(y_test, num_classes = 10)</pre>
34
35 #256 neurons, dropout rate 0.25
36 model <- keras_model_sequential() %>%
37
      layer_dense(units = 256, activation = "relu", input_shape = c(3072)) %>9
38
      layer_dropout(rate = 0.25) %>%
39
      layer_dense(units = 128, activation = "relu") %>%
40
      layer_dropout(rate = 0.25) %>%
41
      layer_dense(units = 64, activation = "relu") %>%
42
      layer_dropout(rate = 0.25) %>%
43
      layer_dense(units = 10, activation = "relu")
44
45 summary(model)
46
47 #set model parameters
48 model %>% compile(
loss = "categorical_crossentropy", #calculate loss
optimizer = optimizer_adam(), #optimization
metrics = c("accuracy") #accuracy
51
    metrics = c("accuracy")
                                            #accuracy
52 )
53
54 #train model
55 history <- model %>%
     fit(
56
57
       x_train, y_train,
                                  #input
58
       epochs = 50,
                                  #128 pictures
59
      batch_size = 128,
       validation_split = 0.15
60
61
      )
62
63 #check quality
64 model %>% evaluate(x_test, y_test)
```

```
Operacje na danych (wersja spłaszczona):
     #----
                              ----- wersja sp³aszczona
 66
     cifar <- dataset_cifar10()</pre>
 68
 69 x_train <- cifar$train$x
 70 x_test <- cifar$test$x</pre>
 71 y_train <- cifar$train$y
 72 y_test <- cifar$test$y</pre>
 73
 74
    #set up data
 75
     #normalize
 76 x_train <- x_train / 255
 77
 78 x_test <- x_test / 255
 79
 80 #set classes
 81 y_train <- to_categorical(y_train, num_classes = 10)
 82 y_test <- to_categorical(y_test, num_classes = 10)</pre>
 83
 84 #create model
 85 model <- keras_model_sequential() %>%
       layer_flatten(input_shape = c(32, 32, 3)) %>%
 87
       layer_dense(units = 128, activation = "relu") %>%
       layer_dense(units = 10, activation = "softmax")
 88
 89
 90 #print model
 91 summary(model)
 92
 93 #set model parameters
 94 model %>% compile(
      loss = "categorical_crossentropy",
 95
                                               #calculate loss
 96
       optimizer = optimizer_adam(),
                                               #optimization
 97
      metrics = c("accuracy")
                                               #accuracy
 98 )
 99
100 #train model
101 history <- model %>%
      fit(
102
        x_train, y_train,
103
104
         epochs = 50,
105
         batch_size = 128,
106
         validation_split = 0.15
      )
107
108
109 #check model quality
110 model %>% evaluate(x_test, y_test)
111
112 #predict
113 model %>% predict(x_test) %>% k_argmin()
```

4. Wynik działania:

Kod programu dostępny w repozytorium: https://github.com/Jaro233/APU.git


Wytrenowany model wersji liniowej:



Jakość modelu wersji liniowej:

```
> model %>% evaluate(x_test, y_test)
```

Wytrenowany model wersji spłaszczonej:



Jakość modelu wersji spłaszczonej:

5. Wnioski:

Dzięki bibliotece tensorflow i keras możliwe było trenowanie modelu oraz ocenienie jego jakości.